

# Alineación de secuencias

# Alineación de secuencias

## Entrada:

- Dos cadenas  $X = \{x_1, x_2, \dots, x_M\}$ ,  $Y = \{y_1, y_2, \dots, y_N\}$  de algún alfabeto determinado (G, T, C, A por ejemplo)
- Una penalidad positiva  $\alpha$  por insertar un vacío (gap)
- Una penalidad positiva  $\beta$  por desigualdad de caracteres

**Salida:** Alineación (secuencia de inserción de vacíos en X, Y) que minimice la penalidad total.

**Ejemplo:** Si  $X = GATACA$ ,  $Y = AACT$ ,  $\alpha = 1$ , y  $\beta = 1.5$

G	A	T	A	C	A
-	A	-	A	C	T

con penalidad total de  $1+1+1.5=3.5$

# Solución mediante programación dinámica

¿Qué forma debería tener la solución óptima de un subproblema?

Dados los primeros  $i$  elementos de  $X$  y los  $j$  primeros elementos de  $Y$  la solución óptima para ese subproblema consistiría en elegir una de las siguientes opciones:

$i$ primeros elementos de $X$ + vacíos	?
$j$ primeros elementos de $Y$ + vacíos	?

1. Incluir el elemento  $i+1$  de  $X$  y el  $j+1$  de  $Y$ , sumar la penalidad resultante a la mínima posible obtenida con los previos  $i$  elementos de  $X$  y los previos  $j$  elementos de  $Y$
2. Incluir el elemento  $i+1$  de  $X$  y un vacío en  $Y$ , sumar la penalidad resultante a la mínima posible obtenida con los previos  $i$  elementos de  $X$  y los previos  $j-1$  elementos de  $Y$
3. Incluir un vacío en  $X$  y el elemento  $j+1$  de  $Y$ , sumar la penalidad resultante a la mínima posible obtenida con los previos  $i-1$  elementos de  $X$  y los previos  $j$  elementos de  $Y$

# Solución mediante programación dinámica

for  $i = 0$  to  $M$ :

$$P_{i,0} = i * \alpha$$

for  $j = 0$  to  $N$ :

$$P_{0,j} = j * \alpha$$

for  $i = 1$  to  $M$

for  $j = 1$  to  $N$ :

$$P_{i,j} = \text{MIN} \begin{cases} P_{i-1,j-1} + \beta \text{ if } X_i \neq Y_j, \text{ else } P_{i-1,j-1} \\ P_{i,j-1} + \alpha \\ P_{i-1,j} + \alpha \end{cases}$$

**Ejemplo:** para  $X = ATA$ ,  $Y = TAC$ ,  $\alpha = 1$ , y  $\beta = 3$

		j Caracteres de Y			
			T	A	C
i Caracteres de X		0	1	2	3
	0	0	1	2	3
	A	1	2	1	2
	T	2	2	1	3
	A	3	3	2	<b>2</b>

¿Cuál debe ser la solución para los casos base?, es decir, para  $P_{i,0}$  y  $P_{0,j}$ ?

$i * \alpha$ ,  $j * \alpha$  respectivamente

¿Cuál es la eficiencia de este algoritmo?  $O(MN)$


# Backtracking para obtener la subsecuencia

if  $X_i = Y_j$ :

$X_i + Y_j$

else:

$\text{MIN}(P_{i-1,j-1}, P_{i,j-1} \rightarrow Y_j + \text{gap en } X, P_{i-1,j} \rightarrow X_i + \text{gap en } Y)$



Si  $i = 0$  ó  $j = 0$  se 'rellenan' los espacios sobrantes de la cadena que ya se terminó con vacíos

		Caracteres de Y			
			T	A	C
Caracteres de X	i	0	1	2	3
	0	0	1	2	3
	A	1	2	1	2
	T	2	2	1	3
	A	3	3	2	1

$\begin{matrix} - & T & A & C \\ A & T & A & - \end{matrix}$